PROPOSAL ĐỀ TÀI CUỐI KỲ MÔN MÁY HỌC

DỰ ĐOÁN MỨC TIÊU THỤ ĐIỆN NĂNG CỦA THIẾT BỊ GIA DỤNG

(Appliances Energy Prediction)

1. Thông tin nhóm

Nhóm: Nhóm XX | **Nhóm trưởng:** [Họ và tên – Thành viên 1]

STT	Họ và tên	MSSV	Nhiệm vụ dự kiến
1	[Họ tên] (nhóm trưởng)	[MSSV]	Điều phối, khung pipeline, huấn luyện và tinh chỉnh XGBoost, tổng hợp báo cáo
2	[Họ tên]	[MSSV]	Thu thập dữ liệu, EDA, trực quan hóa, phân tích tương quan theo thời gian
3	[Họ tên]	[MSSV]	Tiền xử lý, xây dựng đặc trưng (thời gian, lag, rolling), mô hình baseline
4	[Họ tên]	[MSSV]	Huấn luyện Random Forest/MLP, đánh giá, phân tích lỗi và giải thích mô hình

2. Giới thiệu bài toán

Bối cảnh. Các hộ gia đình chiếm tỷ trọng đáng kể trong tổng điện năng tiêu thụ, trong đó điện cho thiết bị gia dụng (tủ lạnh, máy giặt, máy sấy, thiết bị nhà bếp, giải trí…) là thành phần khó dự đoán do phụ thuộc vào hành vi sinh hoạt của người dùng. Cùng với sự phát triển của nhà thông minh và lưới điện thông minh (smart grid), việc dự báo ngắn hạn nhu cầu điện của từng hộ gia đình ngày càng quan trọng.

Lý do chọn đề tài. Bộ dữ liệu có nguồn gốc rõ ràng, được công bố kèm công trình khoa học, kích thước vừa phải (gần 20.000 mẫu), gồm nhiều nhóm đặc trưng khác nhau (nhiệt độ/độ ẩm trong nhà, thời tiết ngoài trời, chiếu sáng), phù hợp để thực hành toàn bộ quy trình Máy học: khám phá dữ liệu, xây dựng đặc trưng, so sánh nhiều mô hình hồi quy và phân tích lỗi.

Ý nghĩa thực tiễn. Dự đoán tốt mức tiêu thụ điện giúp (i) hệ thống quản lý năng lượng nhà thông minh lập lịch vận hành thiết bị, (ii) nhà cung cấp điện cân đối phụ tải và giảm chi phí, (iii) người dùng nhận biết yếu tố ảnh hưởng để tiết kiệm điện.

Mục tiêu và câu hỏi nghiên cứu.

- Xây dựng mô hình dự đoán mức tiêu thụ điện của thiết bị gia dụng (Wh) trong mỗi khoảng 10 phút từ dữ liệu cảm biến và thời tiết.
- **Q1:** Mô hình nào (tuyến tính, cây quyết định tổ hợp, mạng nơ-ron) cho sai số thấp nhất và ổn định nhất trên dữ liệu kiểm tra theo thời gian?
- **Q2:** Các đặc trưng thời gian (giờ, ngày trong tuần) và đặc trưng trễ (lag) cải thiện hiệu năng bao nhiêu so với chỉ dùng dữ liệu cảm biến thô?
- **Q3:** Nhóm đặc trưng nào (nhiệt độ/độ ẩm trong nhà, thời tiết ngoài trời, thời gian) đóng góp quan trọng nhất vào dự đoán?

3. Xác định bài toán Máy học

Yếu tố	Mô tả
Loại bài toán	Học có giám sát – **Hồi quy (Regression)** trên dữ liệu chuỗi thời gian đa biến (dự đoán điểm, one-step).

Yếu tố	Mô tả
Đầu vào	Nhiệt độ và độ ẩm của 9 khu vực trong nhà; điện cho chiếu sáng; nhiệt độ, độ ẩm, áp suất, tốc độ gió, tầm nhìn, điểm sương ngoài trời; đặc trưng thời gian và đặc trưng trễ do nhóm xây dựng.
Đầu ra	Biến mục tiêu liên tục *Appliances* – điện năng tiêu thụ của thiết bị gia dụng (Wh) trong 10 phút.

4. Mô tả dữ liệu

Nguồn: UCI Machine Learning Repository – *Appliances Energy Prediction* (https://archive.ics.uci.edu/dataset/374/appliances+energy+prediction). Dữ liệu do Candanedo, Feldheim và Deramaix thu thập tại một ngôi nhà ở Bỉ, giấy phép CC BY 4.0, công bố trong bài báo trên tạp chí *Energy and Buildings* (2017).

Đặc điểm	Giá trị
Số mẫu / số thuộc tính	19.735 mẫu; 29 thuộc tính (gồm cột thời gian *date* và biến mục tiêu)
Tần suất / thời gian	Mỗi 10 phút, khoảng 4,5 tháng (từ 11/01/2016 đến 27/05/2016)
Biến mục tiêu	*Appliances* (Wh), phân phối lệch phải, có nhiều giá trị cao bất thường (spike)
Thuộc tính trong nhà	*T1–T9* (nhiệt độ, °C), *RH_1–RH_9* (độ ẩm, %), *lights* (điện chiếu sáng, Wh)
Thuộc tính ngoài trời	*T_out, RH_out, Press_mm_hg, Windspeed, Visibility, Tdewpoint* (từ trạm thời tiết sân bay gần nhất)
Biến ngẫu nhiên	*rv1, rv2* – hai biến nhiễu ngẫu nhiên, dùng để kiểm tra tính hữu ích của đặc trưng
Đặc điểm khác	Không có giá trị thiếu theo mô tả của tác giả; cần kiểm tra lại. Dữ liệu có tự tương quan theo thời gian.

5. Phương pháp dự kiến

Khám phá dữ liệu (EDA). Thống kê mô tả; phân phối biến mục tiêu và biến đổi log để giảm lệch; chuỗi thời gian theo ngày/tuần; trung bình tiêu thụ theo giờ và theo thứ; ma trận tương quan; phát hiện ngoại lai và giá trị bất thường.

Tiền xử lý. Kiểm tra thiếu/trùng, chuyển *date* sang kiểu thời gian; chuẩn hóa (StandardScaler) cho mô hình nhạy với thang đo (Ridge, MLP), không cần với mô hình dựa trên cây; xử lý ngoại lai bằng cách giữ nguyên với mô hình cây và thử winsorize/biến đổi log để so sánh; loại các đặc trưng nhiễu hoặc đa cộng tuyến cao (kiểm tra *rv1, rv2*, các cặp T/RH tương quan mạnh).

Xây dựng đặc trưng.

- Đặc trưng thời gian: giờ, phút, thứ trong tuần, cuối tuần/ngày thường, số giây tính từ nửa đêm; mã hóa tuần hoàn (sin/cos) cho giờ.
- Đặc trưng trễ và cửa sổ trượt của *Appliances* (lag 1–6, trung bình trượt 30–60 phút); chỉ dùng thông tin quá khứ để tránh rò rỉ dữ liệu.
- Đặc trưng chênh lệch: T_trong – T_out, trung bình nhiệt độ/độ ẩm các phòng.

Mô hình đề xuất (tối thiểu 02, nhóm dự kiến 03 mô hình chính và 01 mô hình mở rộng):

Mô hình	Vai trò	Cơ sở lựa chọn
Ridge / Linear Regression	Baseline có thể diễn giải	Đơn giản, nhanh; cho biết mức độ quan hệ tuyến tính; Ridge giảm đa cộng tuyến giữa các T/RH.
Random Forest Regressor	Mô hình chính 1	Nắm bắt quan hệ phi tuyến và tương tác, ít nhạy ngoại lai, cho độ quan trọng đặc trưng.

Mô hình	Vai trò	Cơ sở lựa chọn
XGBoost / Gradient Boosting	Mô hình chính 2	Thường mạnh nhất trên dữ liệu bảng; tác giả bộ dữ liệu cũng ghi nhận gradient boosting cho kết quả tốt nhất.
MLP Regressor (mở rộng)	Tùy chọn	Mô hình nơ-ron cơ bản để so sánh với nhóm mô hình dựa trên cây.

6. Kế hoạch thực nghiệm

- **Chia dữ liệu theo thời gian (không xáo trộn):** 70% đầu để huấn luyện, 15% tiếp theo để kiểm định, 15% cuối để kiểm tra. Lý do: dữ liệu chuỗi thời gian, chia ngẫu nhiên gây rò rỉ thông tin từ tương lai. Khi tinh chỉnh dùng *TimeSeriesSplit* (expanding window).
- **Baseline:** (i) dự đoán bằng trung bình tập huấn luyện; (ii) dự đoán bằng giá trị bước trước (persistence); (iii) Ridge Regression.
- **Độ đo:** RMSE (chỉ số chính), MAE, R^2, và MedAE/MAPE để phản ánh sai số ở mức tiêu thụ thấp và cao; so sánh thêm sai số theo khung giờ.
- **Tinh chỉnh:** RandomizedSearchCV hoặc Optuna với TimeSeriesSplit cho Random Forest và XGBoost (số cây, độ sâu, learning rate, subsample, min_samples_leaf…); Ridge tinh chỉnh hệ số alpha; early stopping cho XGBoost/MLP.
- **Phân tích bổ sung (ablation):** so sánh bộ đặc trưng thô, thêm đặc trưng thời gian, thêm đặc trưng lag; phân tích lỗi, độ quan trọng đặc trưng (feature importance, permutation importance, SHAP nếu khả thi).

7. Kết quả dự kiến

- **Sản phẩm:** mã nguồn Jupyter Notebook/Python tái lập được; báo cáo cuối kỳ; slide thuyết trình; bảng so sánh mô hình.
- **Kỳ vọng:** các mô hình cây tổ hợp vượt baseline tuyến tính rõ rệt; đặc trưng thời gian và lag cải thiện đáng kể sai số. Do biến mục tiêu nhiễu và nhiều spike, nhóm kỳ vọng R^2 ở mức vừa phải và không đặt mục tiêu số cụ thể trước khi thực nghiệm.
- **Hướng phát triển:** dự báo nhiều bước (multi-step), thử mô hình chuỗi thời gian (LSTM, Prophet); demo ứng dụng nhỏ (Streamlit) nhập điều kiện đo và trả về mức điện dự đoán.

8. Kế hoạch thực hiện

Tuần	Công việc chính	Phụ trách
1	Chốt đề tài, tải dữ liệu, thiết lập môi trường và kho mã chung, viết proposal	Cả nhóm
2	EDA, trực quan hóa, kiểm tra chất lượng dữ liệu	TV2, TV1
3	Tiền xử lý, xây dựng đặc trưng, chia dữ liệu, huấn luyện baseline	TV3, TV2
4	Huấn luyện Random Forest, XGBoost, MLP (nếu có)	TV4, TV1
5	Tinh chỉnh siêu tham số, ablation, phân tích lỗi và giải thích mô hình	TV1, TV4, TV3
6	Tổng hợp kết quả, viết báo cáo, làm slide, (tùy chọn) demo	Cả nhóm

TV = thành viên theo số thứ tự ở mục 1. Nhóm họp định kỳ hằng tuần; mã nguồn quản lý bằng Git/GitHub.

9. Tài liệu tham khảo

[1] L. M. Candanedo, V. Feldheim, D. Deramaix, “Data driven prediction models of energy use of appliances in a low-energy house,” *Energy and Buildings*, vol. 140, pp. 81–97, 2017.

[2] Candanedo, L. (2017). Appliances Energy Prediction [Dataset]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/374/appliances+energy+prediction

[3] T. Chen, C. Guestrin, “XGBoost: A scalable tree boosting system,” *KDD*, 2016.

[4] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, pp. 5–32, 2001.

[5] F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” *JMLR*, vol. 12, pp. 2825–2830, 2011.