DANH SÁCH ĐỀ TÀI VÀ TẬP DỮ LIỆU GỢI Ý MÔN MÁY HỌC

Danh sách dưới đây ưu tiên các tập dữ liệu có nguồn công khai, rõ ràng, có thể tải trực tiếp, và phù hợp để sinh viên thực hiện trọn vẹn pipeline học máy: khám phá dữ liệu, tiền xử lý, xây dựng đặc trưng, lựa chọn mô hình, huấn luyện, tinh chỉnh, đánh giá và thảo luận kết quả.

1. Nguyên tắc lựa chọn đề tài

- Mỗi nhóm chọn một bài toán chính: hồi quy, phân lớp, gom nhóm hoặc mạng nơ-ron cơ bản; không cần chạy nhiều loại bài toán chỉ để tăng số lượng mô hình.
- Ưu tiên dataset có nguồn chính thức hoặc kho dữ liệu học thuật uy tín (UCI, CDC, cơ quan nhà nước, tổ chức nghiên cứu).
- Phải xác định rõ input, output/target, cách chia dữ liệu, baseline, độ đo đánh giá và ít nhất hai mô hình phù hợp để so sánh.
- Với dữ liệu mất cân bằng hoặc dữ liệu theo thời gian, sinh viên phải chọn chiến lược đánh giá phù hợp và tránh data leakage.
- Sinh viên được phép đề xuất dataset khác nhưng phải nêu rõ nguồn gốc và được giảng viên duyệt trước.

2. Danh sách dataset và bài toán gợi ý

STT	Dataset	Năm	Bài toán gợi ý	Loại ML	Mức độ
1	Predict Students' Dropout and Academic Success	2021	Dự đoán sinh viên Dropout / Enrolled / Graduate	Classification đa lớp	Trung bình
2	CDC Diabetes Health Indicators	2023	Dự đoán nguy cơ tiểu đường từ chỉ số sức khỏe và lối sống	Classification	Trung bình
3	AI4I 2020 Predictive Maintenance	2020	Dự đoán lỗi thiết bị và nhu cầu bảo trì	Classification / Regression	Trung bình
4	RT-IoT2022	2024	Phát hiện normal/attack hoặc phân loại kiểu tấn công IoT	Classification đa lớp	Khá
5	Online Retail II	2019	Phân khúc khách hàng bằng RFM và hành vi mua hàng	Clustering	Khá
6	Product Classification and Clustering	2023	Phân loại hoặc gom nhóm sản phẩm	Classification / Clustering	Khá
7	Wine Quality	2009	Dự đoán điểm chất lượng sản phẩm	Regression / Classification	Cơ bản
8	Appliances Energy Prediction	2017	Dự đoán mức tiêu thụ năng lượng của thiết bị	Regression	Trung bình
9	Metro Interstate Traffic Volume	2019	Dự đoán lưu lượng giao thông theo thời gian và thời tiết	Regression	Khá
10	Beijing Multi-Site Air Quality	2019	Dự đoán PM2.5 / chất lượng không khí	Regression	Khá
11	Individual Household Electric Power Consumption	2012	Dự đoán hoặc phân nhóm mô hình tiêu thụ điện hộ gia đình	Regression / Clustering	Khá
12	WESAD (Wearable Stress and Affect Detection)	2018	Nhận diện trạng thái stress từ cảm biến đeo	Classification / MLP	Khá - Giỏi
13	Diabetes 130-US Hospitals	2014	Dự đoán nguy cơ tái nhập viện của bệnh nhân tiểu đường	Classification	Khá
14	Bank Marketing	2012	Dự đoán khách hàng có đăng ký tiền gửi kỳ hạn	Classification	Cơ bản
15	Online Retail	2015	Phân khúc khách hàng bằng RFM hoặc dự đoán khách hàng giá trị cao	Clustering / Classification	Trung bình

3. Mô tả chi tiết từng đề tài

01. Predict Students' Dropout and Academic Success

Lĩnh vực: Giáo dục

Bài toán: Dự đoán sinh viên Dropout / Enrolled / Graduate

Loại học máy: Classification đa lớp

Input: Thông tin tuyển sinh, nhân khẩu học, kinh tế-xã hội, kết quả học kỳ

Output/Target: Trạng thái học tập

Thuật toán gợi ý: Logistic Regression, KNN, Decision Tree, Random Forest, SVM

Độ đo gợi ý: Macro-F1, Accuracy, Confusion Matrix

Nguồn tải dữ liệu: https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success

2. CDC Diabetes Health Indicators

Lĩnh vực: Y tế

Bài toán: Dự đoán nguy cơ tiểu đường từ chỉ số sức khỏe và lối sống

Loại học máy: Classification

Input: BMI, huyết áp, vận động, tuổi, hành vi sức khỏe...

Output/Target: Diabetes / Pre-diabetes / Healthy

Thuật toán gợi ý: Logistic Regression, Random Forest, SVM, MLP

Độ đo gợi ý: F1, Recall, ROC-AUC

Nguồn tải dữ liệu: https://archive.ics.uci.edu/dataset/891/cdc+diabetes+health+indicators

3. AI4I 2020 Predictive Maintenance

Lĩnh vực: Công nghiệp **Mức độ:** Trung bình

Bài toán: Dự đoán lỗi thiết bị và nhu cầu bảo trì

Loại học máy: Classification / Regression

Input: Nhiệt độ, tốc độ quay, torque, tool wear...

Output/Target: Machine failure / failure mode

Thuật toán gợi ý: Logistic Regression, Tree, Random Forest, Gradient Boosting

Độ đo gợi ý: F1, Recall, ROC-AUC

Nguồn tải dữ liệu: https://archive.ics.uci.edu/dataset/601/ai4i+2020+predictive+maintenance+dataset

4. RT-IoT2022

Lĩnh vực: An ninh mạng / IoT

Bài toán: Phát hiện normal/attack hoặc phân loại kiểu tấn công IoT

Loại học máy: Classification đa lớp

Input: Network traffic features

Output/Target: Normal hoặc loại tấn công

Thuật toán gợi ý: KNN, Decision Tree, Random Forest, SVM, MLP

Độ đo gợi ý: Macro-F1, Recall, Confusion Matrix

Nguồn tải dữ liệu: https://archive.ics.uci.edu/dataset/942/rt-iot2022

5. Online Retail II

Lĩnh vực: Kinh doanh

Bài toán: Phân khúc khách hàng bằng RFM và hành vi mua hàng

Loại học máy: Clustering

Input: Invoice, Quantity, UnitPrice, CustomerID, thời gian giao dịch

Output/Target: Các cụm khách hàng

Thuật toán gợi ý: K-Means, Hierarchical, DBSCAN, PCA

Độ đo gợi ý: Silhouette, Davies-Bouldin, cluster profiling

Nguồn tải dữ liệu: https://archive.ics.uci.edu/dataset/502/online+retail+ii

6. Product Classification and Clustering

Lĩnh vực: Thương mại điện tử **Mức độ:** Khá

Bài toán: Phân loại hoặc gom nhóm sản phẩm

Loại học máy: Classification / Clustering

Input: Tên/mô tả ngắn, merchant, category-related fields

Output/Target: Nhãn sản phẩm hoặc các cụm sản phẩm

Thuật toán gợi ý: Logistic Regression, SVM, K-Means, Hierarchical

Độ đo gợi ý: Macro-F1 / Silhouette

Nguồn tải dữ liệu: https://archive.ics.uci.edu/dataset/837/product+classification+and+clustering

7. Wine Quality

Lĩnh vực: Thực phẩm

Bài toán: Dự đoán điểm chất lượng sản phẩm

Loại học máy: Regression / Classification

Input: Các đặc tính hóa lý

Output/Target: Quality score hoặc nhóm chất lượng

Thuật toán gợi ý: Linear/Ridge Regression, KNN, Tree, Random Forest

Độ đo gợi ý: MAE, RMSE, R^2 / F1

Nguồn tải dữ liệu: https://archive.ics.uci.edu/dataset/837/product+classification+and+clustering

8. Appliances Energy Prediction

Lĩnh vực: Năng lượng **Mức độ:** Trung bình

Bài toán: Dự đoán mức tiêu thụ năng lượng của thiết bị

Loại học máy: Regression

Input: Nhiệt độ, độ ẩm, điều kiện môi trường, thời gian

Output/Target: Energy consumption

Thuật toán gợi ý: Linear/Ridge, Random Forest Regressor, Gradient Boosting

Độ đo gợi ý: MAE, RMSE, R^2

Nguồn tải dữ liệu: https://archive.ics.uci.edu/dataset/374/appliances+energy+prediction

9. Metro Interstate Traffic Volume

Lĩnh vực: Giao thông

Bài toán: Dự đoán lưu lượng giao thông theo thời gian và thời tiết

Loại học máy: Regression

Input: Thời gian, holiday, weather, temperature...

Output/Target: Traffic volume

Thuật toán gợi ý: Linear Regression, Random Forest, Gradient Boosting, MLP

Độ đo gợi ý: MAE, RMSE, R^2

Nguồn tải dữ liệu: https://archive.ics.uci.edu/dataset/492/metro+interstate+traffic+volume

10. Beijing Multi-Site Air Quality

Lĩnh vực: Môi trường

Bài toán: Dự đoán PM2.5 / chất lượng không khí

Loại học máy: Regression

Input: Các chất ô nhiễm, nhiệt độ, áp suất, gió, thời gian

Output/Target: PM2.5 hoặc pollutant target

Thuật toán gợi ý: Linear/Ridge, Random Forest, Gradient Boosting, MLP

Độ đo gợi ý: MAE, RMSE, R^2

Nguồn tải dữ liệu: https://archive.ics.uci.edu/dataset/501/beijing+multi-site+air+quality+data

11. Individual Household Electric Power Consumption

Lĩnh vực: Năng lượng **Mức độ:** Khá

Bài toán: Dự đoán hoặc phân nhóm mô hình tiêu thụ điện hộ gia đình

Loại học máy: Regression / Clustering

Input: Điện áp, cường độ, công suất, thời gian

Output/Target: Power consumption hoặc cụm hành vi

Thuật toán gợi ý: Linear Regression, RF, K-Means, PCA

Độ đo gợi ý: RMSE / Silhouette

Nguồn tải dữ liệu: https://archive.ics.uci.edu/dataset/501/beijing+multi-site+air+quality+data

12. WESAD (Wearable Stress and Affect Detection)

Lĩnh vực: Wearable / Sức khỏe **Mức độ:** Khá - Giỏi

Bài toán: Nhận diện trạng thái stress từ cảm biến đeo

Loại học máy: Classification / MLP

Input: Tín hiệu sinh lý và chuyển động

Output/Target: Stress / baseline / affective state

Thuật toán gợi ý: KNN, SVM, Random Forest, MLP

Độ đo gợi ý: Macro-F1, Balanced Accuracy

Nguồn tải dữ liệu: https://archive.ics.uci.edu/dataset/501/beijing+multi-site+air+quality+data

13. Diabetes 130-US Hospitals

Lĩnh vực: Y tế

Bài toán: Dự đoán nguy cơ tái nhập viện của bệnh nhân tiểu đường

Loại học máy: Classification

Input: Thông tin điều trị, chẩn đoán, thuốc, đặc điểm bệnh nhân

Output/Target: Readmission class

Thuật toán gợi ý: Logistic Regression, Tree, Random Forest, Gradient Boosting

Độ đo gợi ý: F1, Recall, ROC-AUC

Nguồn tải dữ liệu: https://archive.ics.uci.edu/dataset/296/diabetes+130-us+hospitals+for+years+1999-2008

14. Bank Marketing

Lĩnh vực: Ngân hàng

Bài toán: Dự đoán khách hàng có đăng ký tiền gửi kỳ hạn

Loại học máy: Classification

Input: Thông tin khách hàng và chiến dịch marketing

Output/Target: Yes / No

Thuật toán gợi ý: Logistic Regression, KNN, SVM, Decision Tree, Random Forest

Độ đo gợi ý: F1, Recall, ROC-AUC

Nguồn tải dữ liệu: https://archive.ics.uci.edu/dataset/222/bank+marketing

15. Online Retail

Lĩnh vực: Kinh doanh **Mức độ:** Trung bình

Bài toán: Phân khúc khách hàng bằng RFM hoặc dự đoán khách hàng giá trị cao

Loại học máy: Clustering / Classification

Input: Giao dịch bán lẻ trực tuyến

Output/Target: Cluster hoặc nhãn khách hàng giá trị cao

Thuật toán gợi ý: K-Means, Hierarchical, Logistic Regression, Random Forest

Độ đo gợi ý: Silhouette / F1

Nguồn tải dữ liệu: https://archive.ics.uci.edu/dataset/352/online+retail

4. Gợi ý phân nhóm theo mức độ

Nhóm cơ bản: ML07 Wine Quality, ML14 Bank Marketing, ML01 Student Dropout, ML03 AI4I Predictive Maintenance.

Nhóm trung bình - khá: ML02 CDC Diabetes, ML05 Online Retail II, ML08 Appliances Energy, ML09 Traffic Volume, ML13 Hospital Readmission, ML15 Online Retail.

Nhóm khá - giỏi: ML04 RT-IoT2022, ML06 Product Classification and Clustering, ML10 Beijing Air Quality, ML11 Household Power, ML12 WESAD.

5. Yêu cầu tối thiểu khi thực hiện

- Mô tả rõ nguồn dữ liệu, số mẫu, số thuộc tính và ý nghĩa của các trường quan trọng.
- Thực hiện EDA và tiền xử lý có giải thích; không thao tác máy móc.
- Có baseline và ít nhất 02 mô hình phù hợp để so sánh.
- Có chiến lược train/validation/test hoặc cross-validation phù hợp.
- Tinh chỉnh siêu tham số ít nhất 01 mô hình.
- Đánh giá bằng metric phù hợp với loại bài toán; không chỉ dựa vào Accuracy.
- Phân tích lỗi, overfitting/underfitting, ưu - nhược điểm của các mô hình và giải thích kết quả.
- Nộp notebook/source code có thể chạy lại, README hướng dẫn và trích dẫn đầy đủ nguồn dữ liệu.

6. Lưu ý về dữ liệu

Danh sách trên là nguồn gợi ý. Sinh viên có thể dùng dataset khác nếu có nguồn rõ ràng, hợp pháp, không chứa dữ liệu nhạy cảm không được phép sử dụng và phù hợp với mục tiêu học phần. Không khuyến khích dùng dữ liệu tự sinh hoàn toàn bằng AI hoặc dataset không xác định được nguồn gốc.